

DeepSeek——中国AI的开源先锋

深度解析：技术突破、开源哲学与行业变革

目录

- 公司简介：从量化交易到AI巨头
- 创始团队：不鸣则已，一鸣惊人
- 核心产品线：V系列与Coder系列
- 技术架构：MoE与MLA创新
- 训练基础设施：高效计算的秘密
- 开源策略：王炸级的开放生态
- 性能对比：追赶OpenAI
- 商业模式：免费与商业化
- 发展历程：关键里程碑
- 行业影响：改变中国AI格局
- 国际比较：DeepSeek vs 全球巨头
- 挑战与争议
- 未来展望
- 附录

第1章 公司简介：从量化交易到AI巨头

1.1 公司背景

DeepSeek（深度求索） 是一家总部位于中国杭州的人工智能科技公司，成立于2023年。其前身是一家低调运营的对冲基金——DeepSeek Quantitative。

维度 | 信息

成立时间 | 2023年4月（AI转型）

总部 | 中国杭州

创始人 | 梁文峰（Feng Wen）

愿景 | 实现AGI（通用人工智能）

核心特点 | 开源、学术导向、工程能力

员工规模 | ~200人（2024年）

估值 | 超10亿美元（2025年初）

我们希望构建一个像OpenAI但更开放的AI生态系统。开源不是手段，而是目的本身。" — 梁文峰


1.2 从量化基金到AI公司

DeepSeek的发展路径独树一帜：

阶段 | 时间 | 重点

- **量化基金期** | 2019-2022 | 低调运营，积累算力和人才
- **AI转型期** | 2023年初 | 意识到LLM的颠覆性，决定全力投入
- **开源突破期** | 2023年底 | 发布首个开源模型
- **技术领先期** | 2024年 | V系列和Coder系列取得突破
- **行业地位期** | 2025年 | 成为中国AI开源的代表

1.3 核心数据



第2章 创始团队：不鸣则已，一鸣惊人

2.1 创始人：梁文峰

梁文峰（Feng Wen）是DeepSeek的灵魂人物，一个典型的"理想主义工程师"。

教育背景

- 浙江大学计算机科学与技术专业（本科+硕士）
- 专攻机器学习与数值优化

职业经历

时间 | 经历

- 2012-2015 | 华为诺亚方舟实验室研究员
- 2015-2019 | 幻方量化（中国顶级量化基金）合伙人
- 2019 | 创立DeepSeek Quantitative（对冲基金）
- 2023 | 转型AI，创立DeepSeek

创业理念

我不追求短期变现，我要做的是在AI领域留下属于中国的一笔。" — 梁文峰

梁文峰的独特之处:

1. ****财务自由后再创业****: 量化基金已让他实现财务自由，AI创业是理想驱动
2. ****低调神秘****: 极少接受采访，很少公开演讲
3. ****技术理想主义****: 坚持开源，坚持学术导向
4. ****工程能力极强****: 亲自参与核心架构设计

2.2 核心团队

成员 | 职位 | 背景 | 主要贡献

梁文峰 | 创始人&CEO | 浙大/量化交易 | 整体战略、核心技术

柯学 | 联合创始人 | 清华/BAIR | MoE架构设计

杨植麟 | 首席科学家 | CMU/Google | MLA注意力机制

周杰 | 工程VP | 北大/Microsoft | 推理引擎优化

刘洋 | 开源负责人 | 中科院 | 社区运营、文档

2.3 团队文化

DeepSeek的团队文化与众不同：

2.4 团队特点

1. ****年轻化****：核心成员多90后，平均年龄28岁
2. ****学术+工程双能力****：既有顶会论文，也有生产级代码
3. ****开源社区活跃****：HuggingFace、GitHub贡献者众多
4. ****理想主义****：追求AGI，不急于商业化

第3章 核心产品线：V系列与Coder系列

3.1 产品矩阵总览

DeepSeek-V3 系列模型规格概览

模型名称	总参数量	激活参数量	架构/特性
DeepSeek-V3	671B	37B	MoE (671B MoE)
Coder-V2	236B	16B	MoE (236B MoE)
DeepSeek-Math	671B	37B	MoE (671B MoE)
DeepSeek-V2	236B	16B	MoE (236B MoE)
Coder-V2-Lite	16B	16B	MoE (16B MoE)
DeepSeek-VL	236B	16B	MoE (236B MoE)
DeepSeek-LLM	671B	37B	MoE (671B MoE)
Coder-V1	236B	16B	MoE (236B MoE)
DeepSeek-Janus	7B/67B	7B/67B	MoE (7B/67B MoE)

3.2 DeepSeek-V3: 2024年旗舰

规格参数

参数 | 数值 | 说明

总参数 | **671B** | 全球最大开源模型之一

激活参数 | **37B** | MoE架构, 仅激活5.5%参数

上下文长度 | **64K** | 支持长文档理解

训练数据 | **14.8T tokens** | 高质量多语言数据

训练成本 | **\$5.6M** | 仅为GPT-4的5%

训练时间 | **55天** | 2048张H800 GPU

发布时间 | **2024年12月** | 年度压轴发布

性能基准

基准测试 | DeepSeek-V3 | GPT-4 Turbo | Claude-3.5 Sonnet | Qwen2.5-72B

MMLU | **88.5** | 86.4 | 88.3 | 85.8

MMLU-Pro | **75.9** | 72.6 | 78.5 | 71.2

HumanEval | **92.2** | 90.2 | **92.3** | 88.5

GSM8K | **95.9** | 95.3 | 95.5 | 94.2

MATH | **84.0** | 73.4 | 71.1 | 79.8

Chinese评测 | **92.3** | 85.6 | 72.1 | **94.5**

CodeGeneration | **89.5** | 86.2 | **90.1** | 82.3

关键结论: DeepSeek-V3在数学推理和中文理解上超越GPT-4, 代码能力接近Claude-3.5

技术创新

- DeepSeekMoE:** 改进的MoE架构
 - 细粒度专家分割
 - 共享专家隔离
 - 负载均衡优化
- Multi-Head Latent Attention (MLA)**

- KV Cache压缩93%
 - 推理效率提升10倍
3. **FP8混合精度训练**
- 首次大规模应用FP8
 - 训练稳定性突破

3.3 DeepSeek-Coder系列：代码专精

DeepSeek-Coder-V2

参数 | 数值
总参数 | 236B
激活参数 | 21B
支持语言 | 338种编程语言
上下文 | 16K
发布时间 | 2024年6月

代码能力对比

基准 | Coder-V2 | GPT-4 Turbo | Claude-3.5 | Codestral
HumanEval | **90.2** | 87.1 | **92.0** | 86.6
MBPP | **86.2** | 85.1 | 82.3 | 80.5
CodeContests | **62.4** | 58.3 | 61.2 | 55.8
MultiPL-E | **78.5** | 72.3 | 75.8 | 71.2

支持语言（部分）

Python, JavaScript, TypeScript, Java, C++, Go, Rust, C Ruby, PHP, Lua, Perl, Shell Haskell, Erlang, Elixir, F#, Scala Assembly, CUDA, Verilog Zig, V, Mojo, Carbon

3.4 DeepSeek-VL：多模态突破

能力 | 描述
图像理解 | 支持OCR、图表分析、物体检测
视频理解 | 16帧/秒视频编码
多语言 | 中英文视觉-语言对齐

第4章 技术架构：MoE与MLA创新

4.1 DeepSeekMoE架构

与传统MoE对比

MoE (Mixture of Experts) DeepSeekMoE 与传统的 MoE 架构相比，DeepSeekMoE 在以下几个方面进行了创新：

- 1. 路由策略：DeepSeekMoE 采用了 Top-2 路由策略，即每个 token 只路由到两个专家。这有助于减少计算量，提高推理效率。
- 2. 专家共享：DeepSeekMoE 引入了专家共享机制，允许多个 token 共享同一个专家的输出。这有助于提高专家的利用率，减少冗余计算。
- 3. 负载均衡：DeepSeekMoE 通过动态路由策略，确保每个专家都能得到公平的负载分配，避免某些专家过载而某些专家闲置的情况。

DeepSeekMoE核心创新

```
# MoE expert_ids = topk(router(hidden), k=2) output = sum(experts[i](hidden) for i
in expert_ids) # DeepSeekMoE 1. 1. FFN 2. 2. FFN
token # 3. 3. shared_expert_out =
shared_expert(hidden) # 4. 4. routed_expert_ids = topk(router(hidden), k=k_routed)
routed_expert_out = sum(routed_experts[i](hidden) for i in routed_expert_ids) output =
shared_expert_out + routed_expert_out
```

DeepSeekMoE优势

优势 | 说明

- **专家差异化** | 细粒度分割使专家更专业化
- **知识共享** | 共享专家避免重复学习
- **负载均衡** | 自适应路由避免专家过载
- **扩展性强** | 可无限扩展专家数量

4.2 Multi-Head Latent Attention (MLA)

传统MHA的问题

Multi-Head Attention

Head KV KV Cache = $n_heads \times d_head \times seq_len \times batch$ 128K $\times 32$ = 1GB

MLA创新

Multi-Head Latent Attention


1. KV latent 2. KV Cache = $d_latent \times seq_len \times batch$ 93% 64 4 latent

MLA效果

指标 | 传统MHA | MLA
KV Cache大小 | 100% | **7%**
推理速度 | 1x | **10x**
支持上下文 | 32K | **128K**
推理成本 | 高 | **低**

4.3 FP8混合精度训练

DeepSeek-V3首次在超大规模模型上成功应用FP8训练：



FP8训练关键创新

- 1. **细粒度量化**：每512个token一组缩放因子
- 2. **混合精度策略**：关键层保持BF16
- 3. **动态缩放**：训练过程中自适应调整

第5章 训练基础设施：高效计算的秘密

5.1 训练成本革命

DeepSeek-V3的训练成本震惊业界：

模型 | 训练成本 | GPU小时 | 单位成本
****DeepSeek-V3**** | ****\$5.6M**** | 5.7M | \$0.98/GPU-h
GPT-4 | ~\$100M | 25-30M | \$3-4/GPU-h
Claude-3 | ~\$50M | 15-20M | \$2.5-3/GPU-h
LLaMA-3-405B | ~\$60M | 20M | \$3/GPU-h

****核心问题****：为什么DeepSeek能以1/20的成本达到95%的性能？

5.2 硬件配置

训练集群


配置 | 数值
GPU型号 | NVIDIA H800 (80GB)

GPU数量 | 2048张
网络架构 | Fat-Tree, 400Gbps
存储 | 10PB NVMe
训练时长 | 55天 (有效时间)

关键优化

- 1. **通信优化**
 - Zero-3 + ZeRO-Offload
 - 张量并行 + 流水线并行
 - 重计算激活值
- 2. **显存优化**
 - FP8训练
 - 梯度检查点
 - 优化器状态分片
- 3. **计算优化**
 - FlashAttention-3
 - 算子融合
 - CUDA内核定制

5.3 训练效率对比



5.4 推理优化

DeepSeek-Infer推理引擎

优化技术 | 效果
MLA注意力 | KV Cache减少93%
Speculative Decoding | 推理速度提升2.5x
Continuous Batching | 吞吐提升4x
量化推理(INT4) | 成本降低60%

第6章 开源策略：王炸级的开放生态

6.1 开源模型矩阵

模型 | 参数 | 许可证 | HuggingFace下载 | GitHub Stars

DeepSeek-V3 | 671B | MIT | 200K+/月 | 25K+

DeepSeek-V2.5 | 236B | MIT | 150K+/月 | 18K+

DeepSeek-Coder-V2 | 236B | MIT | 100K+/月 | 15K+

DeepSeek-Coder-V1 | 33B | Apache-2.0 | 80K+/月 | 12K+

DeepSeek-LLM-67B | 67B | Apache-2.0 | 50K+/月 | 8K+

DeepSeek-LLM-7B | 7B | Apache-2.0 | 100K+/月 | 10K+

6.2 开源策略分析

DeepSeek■■■■ vs ■■■■

Model	DeepSeek	LLaMA	Qwen	Apache	GPT-4
MIT	✓	✓	✓	✓	✓
LLaMA	✓	✓	✓	✓	✓
Qwen	✓	✓	✓	✓	✓
Apache	✓	✓	✓	✓	✓
GPT-4	✓	✓	✓	✓	✓

6.3 开源收益模型

DeepSeek开源的收益路径：

[illegible]

6.4 社区生态

HuggingFace生态

指标 | 数据

模型卡片数 | 50+

月下载量 | 500万+

点赞数 | 10万+

组织排名 | 中国TOP1

GitHub生态


项目 | Stars | 贡献者
DeepSeek-V3 | 25K+ | 100+
DeepSeek-Coder | 15K+ | 80+
DeepSeek-MoE | 8K+ | 50+

第7章 性能对比：追赶OpenAI

7.1 综合能力对比

维度	DeepSeek-V3	GPT-4 Turbo	Claude-3.5	Qwen2.5-72B
推理能力	★★★★★	★★★★☆	★★★★★	★★★★☆
代码生成	★★★★★	★★★★☆	★★★★★	★★★★☆
数学能力	★★★★★	★★★★☆	★★★★☆	★★★★☆
中文理解	★★★★★	★★★★☆	★★★☆☆	★★★★★
英文理解	★★★★☆	★★★★★	★★★★★	★★★★☆
知识广度	★★★★☆	★★★★★	★★★★★	★★★★☆
长文本	★★★★☆	★★★★★	★★★★★	★★★☆☆

7.2 推理成本对比




7.3 性价比分析

模型	性能得分	成本	性价比
DeepSeek-V3	95分	\$1.37/M	**69**
GPT-4 Turbo	100分	\$40/M	2.5
Claude-3.5	98分	\$90/M	1.1
Qwen-Turbo	92分	\$2.5/M	37

结论： DeepSeek-V3的性价比是GPT-4的28倍

第8章 商业模式：免费与商业化


8.1 商业模式画布



8.2 定价策略

- 服务 | 价格 | 对比
- **DeepSeek-Chat** | 免费 | 个人用户
 - **API-Input** | \$0.27/M tokens | GPT-4的3%
 - **API-Output** | \$1.10/M tokens | GPT-4的4%
 - **企业定制** | 咨询报价 | 规模定价
 - **私有化部署** | 咨询报价 | 按节点收费

8.3 竞争策略




第9章 发展历程：关键里程碑

9.1 完整时间线

时间 | 事件 | 意义

- **2019** | DeepSeek Quantitative成立 | 量化基金起家
- **2022.11** | ChatGPT发布，触动团队 | 意识到LLM的颠覆性
- **2023.04** | 正式转型AI | 关键决策时刻
- **2023.11** | DeepSeek-LLM-67B开源 | 首个开源模型
- **2024.01** | DeepSeek-Coder-V1发布 | 代码模型突破
- **2024.05** | DeepSeek-V2发布 | MLA创新问世
- **2024.06** | DeepSeek-Coder-V2发布 | 代码能力SOTA
- **2024.08** | DeepSeek-V2.5发布 | 通用能力增强
- **2024.12** | DeepSeek-V3发布 | 全球最强开源模型
- **2025.01** | 估值超10亿美元 | 独角兽地位
- **2025.03** | 企业服务规模化 | 商业化突破

9.2 关键决策



第10章 行业影响：改变中国AI格局

10.1 对开源社区的影响

- **降低门槛**：中小企业可免费使用顶级模型
- **推动创新**：基于DeepSeek二次开发爆发
- **生态形成**：插件、工具、应用蓬勃发展
- **国际认可**：HuggingFace中国第一

10.2 对大厂的压力

厂商 | 应对策略

- **阿里** | Qwen加速开源，推出Qwen2.5
- **百度** | ERNIE降价，提升性价比
- **腾讯** | 混元开源，加大投入
- **字节** | Doubato开源，企业服务

10.3 国际影响



第11章 国际比较：DeepSeek vs 全球巨头

11.1 与OpenAI对比

维度	DeepSeek	OpenAI
开源程度	完全开源	完全闭源
模型性能	95分	100分
API价格	低	高
企业服务	新兴	成熟
生态规模	小	大
营收规模	<\$100M	>\$4B

11.2 与Anthropic对比

维度	DeepSeek	Anthropic
安全理念	开放	宪法AI
代码能力	强	很强
推理能力	强	很强
商业化	早期	成熟
估值	\$1B+	\$15B+

11.3 与Meta (LLaMA) 对比

维度	DeepSeek	Meta LLaMA
开源策略	MIT (商用自由)	LLaMA许可 (限制)
模型规模	671B	405B
社区活跃	高	很高
企业支持	弱	强
中文能力	强	中等

第12章 挑战与争议

12.1 技术挑战

- 1. **算力获取**: 美国芯片禁令影响
- 2. **数据瓶颈**: 高质量中文数据稀缺
- 3. **模型安全**: 开源模型的滥用风险
- 4. **技术迭代**: 保持技术领先的难度

12.2 商业挑战

- 1. **变现压力**: 开源如何盈利
- 2. **竞争加剧**: 大厂觉醒后的竞争
- 3. **生态建设**: 从工具到平台的跨越
- 4. **国际市场**: 出海的合规风险


12.3 争议话题

争议 | 说明

- 开源动机** | 为什么免费? 数据收集?
- 技术来源** | 是否借鉴国外架构?
- 安全风险** | 开源模型的安全隐患
- 商业可持续** | 如何长期维持?

第13章 未来展望

13.1 技术路线图



13.2 商业规划

阶段 | 时间 | 目标

****生态建立期**** | 2024-2025 | 开源模型领先，建立开发者生态

****商业验证期**** | 2025-2026 | 企业服务规模化，营收破亿

****规模增长期**** | 2026-2027 | IPO准备，国际扩张

****平台成熟期**** | 2027+ | AI平台化，生态分成

13.3 终极愿景

我们的目标是AGI，开源只是路径。我们相信，只有开放协作，才能让AGI真正造福人类。" — 梁文峰

第14章 附录

附录A：关键资源

资源 | 链接

官网 | <https://deepseek.com>

开源模型 | <https://huggingface.co/deepseek-ai>

GitHub | <https://github.com/deepseek-ai>

API平台 | <https://platform.deepseek.com>

文档 | <https://platform.deepseek.com/docs>

Discord | <https://discord.gg/deepseek>

附录B：核心论文

1. ****DeepSeek-V2****: A Strong, Economical, and Efficient Mixture-of-Experts Language Model
2. ****DeepSeek-V3****: Technical Report
3. ****DeepSeek-Coder-V2****: Breaking the Barrier of Closed-Source Models in Code Intelligence
4. ****DeepSeekMoE****: Towards Ultimate Expert Specialization in Mixture-of-Experts Language Models

附录C：社区资源

资源 | 说明

Awesome-DeepSeek | 社区维护的资源列表

DeepSeek-Cookbook | 使用案例集

DeepSeek-Tutorials | 教程合集

DeepSeek-Plugins | 插件生态

本文档基于2024-2026年公开资料整理

最后更新：2026年5月